

GUIÓN DE EXPOSICIÓN · 5 MINUTOS

Cazadores de patrones en MiniRed

Guion repartido entre dos participantes y guía teórica para explicar el análisis de reglas de asociación con Apriori y Weka.

Gaseosa Lima-Limón → Cerveza Negra

Soporte 1,79 % · Confianza 52,7 % · Resultado estable entre 2024 y 2025

14,26
LIFT

MAPA DE LA EXPOSICIÓN

Cinco minutos, una historia

La exposición sigue el orden de la landing. Cada bloque tiene una idea principal; las tablas acompañan, no se leen completas.

2:30

Santiago: problema, datos y comprobación

2:30

Gael: selección, validación y cierre

1

recomendación comercial concreta

0:00-0:35

Santiago

Pregunta y hallazgo

Abrir con la regla principal y explicar qué significa lift 14,26.

0:35-1:15

Santiago

Preparación

Mostrar el cambio de líneas de venta a matriz binaria y aclarar el alcance multiproducto.

1:15-2:00

Santiago

Corridas en Weka

Comparar soporte 0,05 contra 0,01: ocho reglas frente a 53.

2:00-2:30

Santiago

Verificación manual

Explicar soporte, confianza y lift con una regla; señalar la coincidencia SQL/Weka.

2:30-3:50

Gael

Curaduría

Distinguir la corrida de 190 reglas y justificar las cinco elegidas y un descarte.

3:50-4:30

Gael

Validación temporal

Mostrar que las cinco seleccionadas varían menos del 6 % entre años.

4:30-5:00

Gael

Recomendación, límite e IA

Proponer la prueba comercial, evitar causalidad y declarar el rol de la IA.

Pase acordado: Santiago termina con "Weka comprueba los cálculos, pero todavía no decide qué regla sirve para el negocio". Gael responde: "Ahí empieza la curaduría".

PARTICIPANTE 1

Santiago Skrobacki

Problema → evidencia

0:00-0:35

Pregunta y resultado principal

Mostrar: portada y tarjeta "Gaseosa Lima-Limón → Cerveza Negra".

"Nuestro objetivo fue encontrar qué productos se compran juntos en MiniRed y cuáles de esas asociaciones pueden convertirse en una decisión comercial. El hallazgo principal fue esta regla: entre quienes llevan Gaseosa Lima-Limón, el 52,7 % también lleva Cerveza Negra. Su lift es 14,26; es decir, esa cerveza aparece unas catorce veces más de lo esperable si ambos productos fueran independientes."

CLAVE · Empezar por el hallazgo; no definir todas las métricas todavía.

0:35-1:15

Preparar una canasta válida

Mostrar: tres cifras y transformación línea → matriz.

"Antes de aplicar el algoritmo tuvimos que cambiar el grano de los datos. La tabla original tiene una fila por producto vendido, pero Apriori necesita una fila por ticket y una columna cero o uno por producto. Usamos IdTicket solamente para agrupar y después lo eliminamos. El alcance quedó limitado a las 67.521 canastas con dos o más productos. Esto es importante: al excluir 152.944 tickets unitarios cambian las métricas, por lo que nuestras conclusiones describen compras multiproducto, no todas las ventas."

CLAVE · Presentar la exclusión como alcance metodológico, no como corrección automática.

1:15-2:00

Dos corridas, no una reducción

Mostrar: tarjetas 8 y 53; abrir una captura solo si hace falta.

"Con la misma matriz y confianza mínima de 0,50 hicimos dos ejecuciones. Con soporte 0,05 una asociación debía aparecer en unas 3.376 canastas y Weka encontró ocho reglas. Al bajar el soporte a 0,01 alcanzaban unas 675 canastas y aparecieron 53. No significa que de 53 quedaron ocho: son dos experimentos independientes. Al permitir patrones menos frecuentes, la cantidad de reglas se multiplicó por 6,6."

CLAVE · Señalar que ambas capturas muestran los parámetros y el resultado real de Weka.

2:00-2:30

Comprobación manual y pase

Mostrar: fórmula de la regla principal y tabla "Coincide".

"No aceptamos los valores de Weka sin verificarlos. Para la regla principal contamos 1.210 canastas con ambos productos sobre 67.521: soporte 1,79 %. Al dividir esas 1.210 por las 2.297 canastas con gaseosa obtenemos 52,7 % de confianza; y al compararlo con la frecuencia base de la cerveza obtenemos lift 14,26. Repetimos el control en tres reglas y SQL coincidió con Weka. Pero comprobar un número no decide si la regla sirve para el negocio."

CLAVE · Mirar a Gael para marcar el cambio de participante.

PARTICIPANTE 2

Gael Roldan

Criterio → decisión

2:30-3:15

De 190 reglas a una selección defendible

Mostrar: tarjeta 190 y proceso de seis pasos.

“Para curar resultados hicimos una tercera corrida diferente de las anteriores: soporte mínimo 0,01, métrica lift y umbral 1,50. Produjo 190 reglas direccionales. Sobre esa lista aplicamos seis filtros: soporte suficiente, eliminación de redundancias, lift relevante, sentido comercial, una acción posible y estabilidad en otro período. Por eso las 53 reglas sirven para comparar soportes, mientras que las 190 son la base de la curaduría.”

CLAVE · Diferenciar con claridad las tres corridas.

3:15-3:50

Cinco reglas finales y un descarte

Mostrar: tabla final y tarjeta roja.

“Elegimos cinco reglas. En la tabla cada flecha tiene su propia confianza porque la confianza cambia con la dirección; el soporte y el lift, en cambio, son iguales para el par. También descartamos Detergente hacia Palitos Helados aunque su lift es 7,45. No encontramos un mecanismo comercial plausible y, además, su lift cae 43,2 % entre años. Esto demuestra que ordenar por lift y quedarse con los primeros resultados no es una curaduría.”

CLAVE · No leer las cinco filas; señalar la primera y el descarte.

3:50-4:30

Validación 2024 frente a 2025

Mostrar: tabla temporal.

“Para validar, separamos las 33.515 canastas de 2024 y las 34.006 de 2025 y recalculamos el lift. Las cinco reglas elegidas variaron menos del 6 %. La principal pasó de 14,08 a 14,45. Esa estabilidad no prueba causalidad, pero reduce el riesgo de presentar como patrón algo que apareció por una particularidad de un solo período.”

CLAVE · Decir “las cinco seleccionadas”, no generalizar a todas las reglas.

4:30-5:00

Recomendación, límite y rol de la IA

Mostrar: bloque final azul.

“Nuestra recomendación es probar una exhibición conjunta de Gaseosa Lima-Limón y Cerveza Negra durante los fines de semana y medir el resultado. Hablamos de una prueba porque la regla muestra coocurrencia, no que un producto cause la compra del otro. La IA ayudó con SQL, el ARFF, comandos y presentación; nosotros verificamos los conteos, las métricas, las direcciones y corregimos afirmaciones que los datos no respaldaban.”

CLAVE · Cerrar en la acción y detenerse; no volver a abrir detalles.

Si se acaba el tiempo: omitir las cinco filas intermedias, pero conservar el descarte, la estabilidad y la recomendación final.

CONCEPTOS FUNDAMENTALES

Qué estamos analizando

Esta parte no forma parte del discurso de cinco minutos. Sirve para estudiar y responder preguntas.

Transacción o canasta

Conjunto de productos comprados en un mismo ticket. Es la unidad de análisis: una fila de la matriz representa una transacción.

Ítem e itemset

Un ítem es un producto. Un itemset es un conjunto de productos, por ejemplo {Gaseosa, Cerveza}.

Matriz binaria

Cada columna es un producto y cada celda indica presencia (1) o ausencia (0). El identificador del ticket no debe entrar como atributo.

Regla de asociación

Expresión $A \rightarrow B$: dentro de las canastas que contienen A, se analiza con qué frecuencia también aparece B.

La dirección importa

$A \rightarrow B$ y $B \rightarrow A$ comparten soporte y lift, pero normalmente tienen distinta confianza porque cambia el denominador.

Ejemplo: Gaseosa Lima-Limón $\rightarrow$ Cerveza Negra tiene confianza 52,7 %. La dirección inversa tiene aproximadamente 48,5 %, aunque ambas tienen lift 14,26.

Alcance del análisis

Se trabajó con 67.521 canastas de dos o más productos. Los tickets unitarios no pueden contener un par, pero excluirlos también modifica los denominadores. Por eso la interpretación correcta es condicional: **patrones dentro de compras multiproducto**.

Coocurrencia no es causalidad

Una regla indica que dos productos aparecen juntos más de lo esperable. No demuestra que comprar A provoque comprar B. Puede haber factores externos: promociones, ubicación, horario, sucursal, estacionalidad o generación de datos.

Frase corta para recordar

Apriori descubre combinaciones frecuentes; el analista decide si son confiables, interpretables y accionables.

MÉTRICAS

Soporte, confianza y lift

Las tres métricas responden preguntas diferentes. Ninguna debería interpretarse aislada.

1. Soporte

¿Qué tan frecuente es la combinación?

$$\text{soporte}(A \rightarrow B) = n(A \cap B) / N$$

Para la regla principal: $1.210 / 67.521 = 0,0179$, es decir, 1,79 % de las canastas.

2. Confianza

Entre quienes llevan A, ¿qué proporción también lleva B?

$$\text{confianza}(A \rightarrow B) = n(A \cap B) / n(A)$$

$1.210 / 2.297 = 0,5268$. Si una canasta contiene Gaseosa Lima-Limón, la probabilidad observada de encontrar Cerveza Negra es 52,7 %.

3. Lift

¿Cuánto mejora la confianza respecto de la frecuencia normal de B?

$$\text{lift}(A \rightarrow B) = \text{confianza}(A \rightarrow B) / \text{soporte}(B)$$

La Cerveza Negra aparece en $2.494 / 67.521 = 3,69$ % de las canastas. Entonces $0,5268 / 0,0369 = 14,26$.

VALOR DEL LIFT	INTERPRETACIÓN	PRECAUCIÓN
> 1	Coocurrencia positiva	Puede ser inestable si el soporte es bajo.
= 1	Comportamiento cercano a independencia	No aporta asociación.
< 1	Aparecen juntos menos de lo esperado	No significa necesariamente sustitución causal.

Por qué la confianza sola engaña: si B es muy popular, muchas reglas hacia B tendrán confianza alta aunque A no aporte información. El lift compara contra esa frecuencia base.

ALGORITMO E INTERPRETACIÓN

De Apriori a la curaduría

El algoritmo reduce la búsqueda; no reemplaza la evaluación metodológica ni comercial.

¿Qué hace Apriori?

Busca itemsets frecuentes por niveles. Usa la propiedad de que, si un conjunto no alcanza el soporte mínimo, ninguno de sus superconjuntos puede alcanzarlo. Así evita probar combinaciones imposibles de forma exhaustiva.

¿Qué hace el soporte mínimo?

Define cuántas canastas debe alcanzar un patrón para ser candidato. Un umbral alto produce pocas reglas robustas; uno bajo encuentra más casos, pero aumenta ruido y trabajo de revisión.

CORRIDA	SOPORTE	MÉTRICA MÍNIMA	RESULTADO	OBJETIVO
Comparación 1	0,05	Confianza 0,50	8 reglas	Filtro exigente
Comparación 2	0,01	Confianza 0,50	53 reglas	Mostrar el efecto del soporte
Curaduría	0,01	Lift 1,50	190 reglas	Evaluar asociaciones por encima del azar

Los seis filtros aplicados

01
Soporte

02
Redundancia

03
Lift

04
Sentido

05
Acción

06
Otro período

¿Por qué validar por año?

Una regla puede deberse a una promoción, carga de datos o período particular. Recalcularla en 2024 y 2025 permite observar estabilidad. En las cinco seleccionadas, el lift varió menos del 6 %.

¿Por qué descartar un lift 7,45?

Detergente → Palitos Helados combina un valor alto con falta de mecanismo comercial y una caída interanual de 43,2 %. Un número llamativo puede ser un artefacto.

Detalle de Weka: tratar cero como ausencia

Los atributos son nominales {0,1}. La opción **treatZeroAsMissing** hace que Weka busque reglas sobre la presencia de productos. Sin ella podrían dominar asociaciones sobre ausencias, que no responden a la pregunta comercial.

Regla práctica

Una buena regla necesita frecuencia suficiente, una mejora real frente al azar, estabilidad y una acción que pueda probarse.

PREGUNTAS PROBABLES

Respuestas cortas para defender el trabajo

Responder primero en una frase. Ampliar solo si el docente lo pide.

¿Por qué sacaron los tickets de un producto?

Definimos un alcance de canastas multiproducto porque buscamos pares. Reconocemos que la exclusión modifica las métricas; por eso no generalizamos a todas las ventas.

¿Por qué 8 reglas y después 53?

Son dos corridas distintas. Al bajar el soporte de 5 % a 1 %, se aceptan combinaciones menos frecuentes y aparecen más reglas.

¿De dónde salen las 190?

De una tercera corrida para curaduría: soporte 0,01, métrica lift y mínimo 1,50. No reemplaza las corridas comparativas.

¿Por qué no elegir solo por lift?

Porque un lift alto puede tener poco soporte, ser inestable o no tener una explicación de negocio. El descarte Detergente-Palitos lo demuestra.

¿La regla principal prueba causalidad?

No. Prueba coocurrencia. La recomendación es realizar un experimento comercial y medir si la exhibición produce un efecto.

¿Cómo verificaron a Weka?

Recalculamos soporte, confianza y lift con conteos independientes desde SQL y obtuvimos los mismos valores, salvo redondeo.

¿Qué hizo la IA?

Ayudó con SQL, ARFF, comandos y comunicación. El grupo verificó métricas, direcciones, estabilidad y corrigió afirmaciones no respaldadas.

¿Cuál es la recomendación concreta?

Probar Gaseosa Lima-Limón junto a Cerveza Negra los fines de semana y evaluar el resultado contra un período o grupo de control.

Checklist antes de presentar

- ✓ Abrir la landing y comprobar las capturas.
- ✓ No leer tablas fila por fila.
- ✓ Diferenciar 53 de 190 reglas.
- ✓ Respetar el pase a los 2:30.
- ✓ Ensayar una vez con cronómetro.
- ✓ Usar "canastas multiproducto".
- ✓ Decir "asociación", no "causa".
- ✓ Cerrar con la prueba comercial.

Idea final para ambos

El algoritmo encuentra patrones. La calidad del trabajo aparece al verificar, descartar, validar y convertir una asociación en una hipótesis comercial medible.