

Cazadores de Patrones en MiniRed

Reglas de asociación sobre MiniRed_DW con Apriori y FP-Growth

- Materia:** Base de Datos Aplicada — Unidad 5
- Actividad:** Clase 8 — De la base de datos real a la regla de negocio
- Integrantes:** (completar)
- Herramientas:** SQL Server 2025 · Weka 3.8.7 · Python 3.14
- Repositorio:** <https://github.com/SantiagoSkrobacki/MiniRed-2>
- Presentación:** <https://santiagoskrobacki.github.io/MiniRed-2/>

1. Fase 0 — Preparación de los datos

1.1 El universo elegido y su justificación

Se trabajó sobre `Fact_Ventas` de `MiniRed_DW`, con el catálogo completo (30 productos), las 7 sucursales y los dos años disponibles (2024-01-01 a 2025-12-31).

No se recortó por sucursal ni por trimestre por una razón concreta: el enunciado sugiere el recorte asumiendo un catálogo de 4.200 artículos, pero la base instalada tiene **30 productos y 7 sucursales**. El espacio de itemsets es lo suficientemente chico como para que Apriori lo recorra completo en segundos, de modo que recortar solo habría reducido la evidencia sin ganar nada en tiempo de cómputo.

Sí se tomó una decisión de recorte, y fue necesaria:

Se excluyeron los tickets con un solo producto distinto: 152.944 de 220.465, el 69 % del total. Una transacción con un único ítem no puede generar ninguna regla de asociación —no hay con qué asociar el producto— pero sí engrosa el denominador N y hunde artificialmente el soporte de todas las reglas. Conservarlos habría dividido todos los soportes por 3,3 sin aportar una sola co-ocurrencia.

1.2 Una corrección al enunciado

El enunciado indica armar la consulta agrupando por `IdVenta`, "el ticket". En `MiniRed_DW` esa columna es la **clave primaria de la línea de detalle**; el ticket es `IdTicket`. Agrupando como indica el texto, cada canasta habría contenido exactamente un producto y Apriori no habría devuelto ninguna regla. Se verificó el esquema de la tabla antes de escribir la consulta y se agrupó por `IdTicket`.

1.3 La transformación de grano

`Fact_Ventas` está en grano de línea. Apriori necesita grano de canasta. El ticket `2024010101298` ilustra la transformación completa:

Origen — grano de línea (3 filas):

IdVenta	IdTicket	Producto	Cantidad	Importe
101.599	2024010101298	Helado Crema 1L	6	\$31.200
224.034	2024010101298	Palitos Helados x6	6	\$18.600
265.822	2024010101298	Detergente 750ml	4	\$7.560

Intermedio — grano de canasta (1 fila):

`2024010101298` → Helado Crema 1L + Palitos Helados x6 + Detergente 750ml

Destino — matriz transaccional para Weka (1 fila, 30 columnas):

Helado	Palitos	Detergente	Leche	Gaseosa	...
1	1	1	0	0	...

En el paso final se descartan `Cantidad`, `ImporteTotal`, `IdCajero` y `IdMedioPago`: a un algoritmo de asociación solo le importa la presencia del ítem, no cuántas unidades ni a qué precio. También se descarta `IdTicket`, que solo sirvió para agrupar.

1.4 Volumen de la muestra final

Métrica	Valor
Líneas en <code>Fact_Ventas</code>	315.969
Tickets totales	220.465

Métrica	Valor
Tickets descartados (1 solo ítem)	152.944 (69 %)
Transacciones analizadas	67.521
Ítems distintos	30
Pares ticket-producto	157.971
Promedio de ítems por ticket	2,34

[CAPTURA 1] — Extracto de la matriz transaccional: las primeras filas del archivo `minired_canasta.arff` mostrando la cabecera con los 30 `@attribute` y las filas de 0 y 1.

1.5 Los tres errores de siempre

Error	Cómo se evitó
Atributo numérico sin discretizar	Los 30 atributos se declararon nominales <code>{0,1}</code> al generar el <code>.arff</code> . No hizo falta aplicar <code>NumericToNominal</code> .
El identificador de ticket como atributo	<code>IdTicket</code> no figura en el archivo: se usó para agrupar y se descartó.
El soporte por defecto demasiado alto	El default de Weka (0,1) no devuelve nada útil sobre esta matriz. Se corrió con 0,05 y con 0,01.

2. Fase 1 — Aplicación del algoritmo

2.1 Configuración

Se usó Weka 3.8.7, `Explorer` → `Associate` → `Apriori`, con `treatZeroAsMissing = True`. Este parámetro es indispensable: sin él, Apriori interpreta el 0 como un valor más y genera reglas sobre la **ausencia** de productos ("quien no lleva X, no lleva Y"), que son ciertas y completamente inútiles.

2.2 Comparación de las dos corridas

	Corrida 1	Corrida 2
Soporte mínimo	0,05	0,01
Instancias mínimas	3.376	675
Confianza mínima	0,5	0,5
Ciclos ejecutados	19	99
Itemsets frecuentes L(1)	26	29
Itemsets frecuentes L(2)	4	57
Reglas obtenidas	8	53
Tiempo	0,81 s	3,70 s

Bajar el soporte de 0,05 a 0,01 multiplicó las reglas por 6,6, y los itemsets de tamaño 2 por 14. Esto ocurre con un catálogo de apenas 30 productos; en una cadena real con 4.200 artículos, el mismo descenso produce decenas de miles de reglas. Es exactamente el problema de "qué hacer con 40.000 reglas": el algoritmo no discrimina, solo cuenta.

[CAPTURA 2] — Weka, corrida 1: soporte 0,05, 8 reglas. **[CAPTURA 3]** — Weka, corrida 2: soporte 0,01, 53 reglas.

2.3 Verificación manual de tres reglas

Se recalcularon tres reglas con las definiciones, mediante consultas SQL directas sobre `MiniRed_DW`. Es un camino **independiente** del de Weka: uno cuenta sobre la base relacional, el otro sobre el archivo `.arff`.

Fórmulas empleadas, con $N = 67.521$:

```

soporte(A,B)    = n(A y B) / N
confianza(A→B)  = n(A y B) / n(A)
lift(A→B)       = confianza(A→B) / ( n(B) / N )

```

Regla 1 — Detergente 750ml → Palitos Helados x6

$n(A) = 6.348$ $n(B) = 6.822$ $n(A \text{ y } B) = 4.778$
 $\text{soporte} = 4.778 / 67.521 = 0,0708$
 $\text{confianza} = 4.778 / 6.348 = 0,7527$
 $\text{base}(B) = 6.822 / 67.521 = 0,1010$
 $\text{lift} = 0,7527 / 0,1010 = 7,45$

Regla 2 — Mermelada Durazno 390g → Caramelos Surtidos 100g

$n(A) = 5.466$ $n(B) = 5.886$ $n(A \text{ y } B) = 4.023$
 $\text{soporte} = 4.023 / 67.521 = 0,0596$
 $\text{confianza} = 4.023 / 5.466 = 0,7360$
 $\text{base}(B) = 5.886 / 67.521 = 0,0872$
 $\text{lift} = 0,7360 / 0,0872 = 8,44$

Regla 3 — Gaseosa Lima-Limón 2.25L → Cerveza Negra 473ml

$n(A) = 2.297$ $n(B) = 2.494$ $n(A \text{ y } B) = 1.210$
 $\text{soporte} = 1.210 / 67.521 = 0,0179$
 $\text{confianza} = 1.210 / 2.297 = 0,5268$
 $\text{base}(B) = 2.494 / 67.521 = 0,0369$
 $\text{lift} = 0,5268 / 0,0369 = 14,26$

Contraste con Weka:

Regla	Conf. calculada	Conf. Weka	Lift calculado	Lift Weka	
Detergente → Palitos	0,7527	0,75	7,450	7,45	Coincide
Mermelada → Caramelos	0,7360	0,74	8,443	8,44	Coincide
Gaseosa L-L → Cerveza	0,5268	0,53	14,262	14,26	Coincide

Las diferencias son únicamente de redondeo: Weka muestra dos decimales. **La coincidencia confirma que la matriz transaccional se construyó correctamente**; si el `.arff` hubiera incluido el identificador de ticket, o si el agrupamiento hubiera estado mal, los valores no habrían coincidido y el error habría pasado inadvertido hasta la exposición.

2.4 Plus — FP-Growth

Algoritmo	Tiempo	Estrategia	Reglas
Apriori	3,29 s	Genera candidatos por nivel y recorre los datos en cada ciclo (99 ciclos)	—
FP-Growth	0,48 s	Comprime los datos en un árbol de prefijos y extrae los patrones sin generar candidatos	Idénticas

FP-Growth resultó **6,9 veces más rápido** y devolvió exactamente las mismas reglas con los mismos valores. La diferencia es de eficiencia algorítmica, no de resultado, que es lo esperable: ambos calculan lo mismo por caminos distintos.

3. Fase 2 — Curaduría de las reglas

3.1 Aplicación de los seis pasos

Paso 1 — Descartar lo trivial. No se encontraron reglas triviales evidentes; con 30 productos genéricos no hay pares tan obvios como "pan → manteca".

Paso 2 — Descartar lo redundante. Las ocho reglas de mayor lift resultaron ser combinaciones de tres y cuatro ítems dentro de dos clusters ya representados por pares simples. Hamburguesas + Detergente → Palitos + Lavandina alcanza lift 36,87, pero no aporta nada sobre los pares que la componen: el lift altísimo es un artefacto de combinar correlaciones ya conocidas. Se descartaron todas las reglas de más de dos ítems.

También se unificaron las reglas gemelas: $A \rightarrow B$ y $B \rightarrow A$ comparten soporte y lift, y solo difieren en la confianza. Presentarlas por separado sería contar dos veces el mismo hallazgo.

Paso 3 — Ordenar por lift. Se reordenó la lista completa por lift descendente. Durante este paso se detectó un problema de configuración: al rankear por lift (-T 1) con pocas reglas solicitadas, Weka detiene la búsqueda al alcanzar esa cantidad y se queda en un soporte alto. La regla de mayor lift del dataset (14,26, soporte 0,018) **quedaba fuera del**

ranking hasta que se forzó el piso con `-M 0.01 -U 0.05 -N 200`. Un ranking por lift no sirve si el piso de soporte excluye la regla de la búsqueda.

Paso 4 — Mecanismo plausible. Se exigió a cada regla una explicación de negocio. Este paso eliminó las reglas que cruzan categorías sin relación de uso: Congelados con Limpieza, Lácteos con Limpieza.

Paso 5 — Accionabilidad. Se conservaron las reglas que permiten una decisión concreta de góndola, promoción o surtido.

Paso 6 — Validar en otro período. Se recalculó el lift por separado sobre 2024 y 2025, usando las matrices `minired_canasta_2024.arff` y `minired_canasta_2025.arff`.

3.2 El hallazgo metodológico

Los pasos 4 y 6 se aplicaron de forma independiente: primero se clasificaron las reglas según si tenían explicación de negocio —criterio puramente cualitativo— y recién después se recalcularon los lift por año.

Los dos criterios señalaron el mismo conjunto de reglas.

Grupo	Ejemplo	Lift total	2024	2025	Variación
Con mecanismo	Gaseosa Lima-Limón + Cerveza Negra	14,26	14,08	14,45	+2,6 %
Con mecanismo	Agua Saborizada + Jugo Naranja	5,47	5,40	5,53	+2,5 %
Sin mecanismo	Palitos Helados + Detergente	7,45	10,31	5,86	−43,2 %
Sin mecanismo	Manteca + Lavandina	5,57	8,13	4,07	−49,9 %
Sin mecanismo	Palitos Helados + Hamburguesas	3,17	0,08	4,52	+5.217 %

Las once reglas con mecanismo plausible varían **menos del 12 %** entre años. Ninguna de las implausibles baja del 29 %. El juicio de negocio y la evidencia estadística convergieron.

Las variaciones extremas merecen una observación aparte. `Palitos + Hamburguesas` pasa de lift 0,08 a 4,52, y `Detergente + Lavandina` de 0,18 a 4,44. **Un lift menor a 1 significa que esos productos se compraban separados.** Un salto de esa magnitud no describe un cambio de hábito de los clientes: indica un cambio estructural en la generación de los datos entre un año y el otro. Se excluyeron del análisis en lugar de presentarlos como un descubrimiento comercial.

3.3 Las siete reglas finales

#	Regla	Soporte	Confianza	Lift	Δ 24–25	Recomendación de negocio
1	Gaseosa Lima-Limón ↔ Cerveza Negra	0,0179	52,7 %	14,26	+2,6 %	Punta de góndola de fin de semana con ambas juntas. Es el combo de previa.
2	Agua Mineral 2L ↔ Yerba Mate 500g	0,0113	45,0 %	8,60	+5,1 %	Ubicar el agua sin gas junto a la yerba, no en la heladera de bebidas.
3	Agua Mineral 2L ↔ Cerveza Negra	0,0108	29,3 %	5,61	+5,9 %	Carga de bebidas en un mismo viaje: conviene ofrecer pack mixto.
4	Agua Saborizada ↔ Cerveza Rubia	0,0437	49,0 %	5,54	+2,6 %	La combinación de bebidas más frecuente del catálogo: exhibir contiguas.
5	Gaseosa Cola ↔ Yerba Mate 1kg	0,0325	63,5 %	5,49	+2,8 %	Compra de reposición del hogar: promoción cruzada en el ticket.
6	Agua Saborizada ↔ Jugo Naranja	0,0355	48,4 %	5,47	+2,5 %	Misma decisión de compra (sin alcohol). Exhibir contiguas.
7	Galletitas Dulces ↔ Leche Entera	0,0915	64,1 %	4,26	+11,2 %	El mayor soporte de todas (9,2 %). Desayuno y merienda: nunca liquidar ambas a la vez.

3.4 Las reglas descartadas

Regla	Lift	Paso	Motivo
Hamburguesas + Detergente → Palitos + Lavandina	36,87	2	Combinación de dos pares ya presentes: no aporta información nueva.
Galletitas + Caramelos → Mermelada + Leche	33,79	2	Cuatro ítems del mismo cluster; el lift es artefacto de combinar correlaciones.
Agua Saborizada + Yerba → Cerveza Rubia	11,20	4	Confianza exactamente 1,00 sobre 731 tickets: demasiado perfecto para ser real.
Mermelada ↔ Caramelos	8,44	6	Mecanismo débil (ambos dulces) y caída del 34 % entre años.
Palitos Helados ↔ Detergente	7,45	4	Congelados con Limpieza: sin explicación posible. Además cae 43 %.

Regla	Lift	Paso	Motivo
Dulce de Leche ↔ Jabón en Polvo	6,98	4	Lácteos con Limpieza. Salta 61 % entre años.
Hamburguesas ↔ Lavandina	5,60	4	Congelados con Limpieza nuevamente.
Manteca ↔ Lavandina	5,57	6	Cae a la mitad (-50 %).
Aceite Girasol ↔ Yogur Bebible	5,07	4	Sin relación de uso ni de ocasión de consumo.
Alfajor ↔ Galletitas Dulces	1,70	3	Confianza 25,6 % que parece aceptable, pero las galletitas están en el 15,1 % de los tickets igual.

3.5 El descarte más relevante

Palitos Helados → Detergente tiene lift **7,45**, el cuarto más alto de todo el dataset, y no existe ninguna explicación de por qué alguien compraría helado junto con detergente. Si el criterio hubiera sido únicamente "ordenar por lift y quedarse con las primeras", esta regla habría entrado a la presentación y MiniRed habría terminado ubicando detergente junto a la heladera de helados.

Un número alto no es un hallazgo. El valor del paso 4 se mide precisamente en las reglas que elimina pese a tener buenas métricas.

4. Fase 3 — Rol de la inteligencia artificial

Se utilizó **Claude (Anthropic)** como asistente.

Qué generó la IA: la consulta SQL de la matriz transaccional, el script de Python que produce el archivo `.arff`, las consultas de verificación de soporte/confianza/lift, los comandos de Weka y el diseño de la presentación web.

Qué hubo que corregir:

1. **El agrupamiento por IdVenta**. Seguir el enunciado al pie producía canastas de un solo ítem. Se detectó revisando el esquema real de la tabla.
1. **El ranking por lift truncado.** Weka detenía la búsqueda en un soporte alto y ocultaba la regla más fuerte del dataset.
1. **Un pipeline de PowerShell** que truncó una salida de Weka y la dejó incompleta.

Dónde confiar ciegamente habría sido un riesgo. No en el código —que falla de forma ruidosa— sino en los **números**. Si se hubieran solicitado los valores de soporte, confianza y lift a un modelo generativo, habría devuelto cifras perfectamente plausibles y no existía forma de detectarlo: nadie observa un lift de 7,45 y sospecha.

Existe un segundo riesgo, más sutil: la **interpretación**. Consultada sobre qué mecanismo de negocio explica una regla, una IA generativa encuentra una justificación convincente para cualquier par de productos, incluso para helado con detergente. Los modelos generativos son eficaces produciendo explicaciones plausibles, que es exactamente lo contrario de lo que requiere el paso 4 de la curaduría.

Por eso el trabajo se apoyó en **dos cálculos independientes** —SQL contra la base y Weka sobre el `.arff`— que coinciden hasta el segundo decimal, y el juicio sobre el mecanismo se emitió antes de consultar los datos de estabilidad. **Ningún valor de soporte, confianza o lift fue estimado.**

5. Conclusiones

1. **La preparación de los datos consumió aproximadamente el 80 % del esfuerzo.** Las dos corridas de Apriori sumaron 4,5 segundos. La desproporción se explica porque el algoritmo resuelve un problema cerrado, mientras que la preparación concentra todas las decisiones sin respuesta única: el grano, el recorte, qué hacer con los tickets de un solo ítem.
1. **Leer la fuente antes de modelarla evitó un error que habría invalidado el trabajo.** El enunciado indicaba agrupar por una columna que no es el ticket.
1. **El algoritmo encuentra correlaciones; el analista encuentra hallazgos.** De 53 reglas estadísticamente ciertas sobrevivieron 7. Las 46 restantes eran redundantes, implausibles o inestables — y todas tenían métricas válidas.
1. **El criterio de negocio resultó ser un predictor de la validez estadística.** Que las reglas con explicación plausible sean exactamente las que se sostienen entre 2024 y 2025 no estaba previsto, y es el resultado que da sustento a toda la curaduría.

Anexos

- **Repositorio completo:** <https://github.com/SantiagoSkrobacki/MiniRed-2>
 - **Presentación interactiva:** <https://santiagoskrobacki.github.io/MiniRed-2/>
 - **Salidas crudas de Weka:** carpeta `weka/` del repositorio (7 corridas)
 - **Consulta SQL documentada:** `sql/01_matriz_transaccional.sql`
 - **Reflexiones individuales:** se adjuntan por separado, una por integrante
-

Fase 4 — Reflexiones individuales

Reflexión individual

Santiago Skrobacki

Preparación de datos y ejecución del algoritmo. Las dos corridas de Apriori tardaron 0,81 y 3,70 segundos: cuatro segundos y medio en total. Todo lo demás —entender el grano de `Fact_Ventas`, escribir la consulta, decidir qué tickets entraban, generar el archivo para Weka y verificar que los números cerraran— se llevó prácticamente todo el tiempo que le dedicamos. La Unidad 4 dice que la preparación consume la mayor parte del esfuerzo y uno lo lee y asiente; medirlo fue distinto. Entendí *por qué* pasa: el algoritmo resuelve un problema cerrado, con una respuesta única, y por eso se automatiza. La preparación es donde están las preguntas que no tienen respuesta correcta, y ninguna de las nuestras venía resuelta en el enunciado.

La advertencia que estuvimos cerca de cometer. Dar por buena una suposición sobre los datos sin verificarla contra la base. El enunciado indicaba agrupar por `IdVenta`, "el ticket", pero en `MiniRed_DW` esa columna es la PK de la línea: el ticket es `IdTicket`. Siguiéndolo al pie, cada canasta habría tenido un solo producto y Apriori no habría devuelto nada. Lo encontramos revisando las columnas antes de escribir la consulta, casi de casualidad; si no, habríamos pasado horas buscando por qué "no hay patrones" cuando el problema estaba en nuestro `GROUP BY`. Me llevo que la fuente gana sobre lo que uno cree de la fuente, incluso cuando eso viene escrito en la consigna.

El rol de la IA. El riesgo no estaba en el código —el código falla ruidosamente— sino en los números. Si le hubiéramos pedido el soporte y el lift en vez de calcularlos, habría devuelto cifras creíbles y no teníamos forma de detectarlo: nadie mira un lift de 7,45 y sospecha. Por eso los calculamos por dos caminos separados, SQL contra la base y Weka sobre el `.arff`, y coincidieron al segundo decimal. Un número que no se puede reproducir por dos vías no entra al informe.

Reflexión individual

(Nombre del segundo integrante)

Preparación de datos y ejecución del algoritmo. Calculo que entre el 80 y el 90 % del tiempo se fue en la Fase 0. Apriori procesó 67.521 transacciones en 3,70 segundos y FP-Growth en 0,48; elegir *cuáles* 67.521 transacciones nos llevó una tarde. Lo que me sorprendió es que la decisión más importante del trabajo no fue técnica sino de criterio: el 69 % de los tickets de MiniRed tiene un solo producto, 152.944 de 220.465. Esos tickets no pueden generar ninguna regla, pero engordan el denominador y hunden todos los soportes. Sacarlos no lo decide ninguna herramienta. Eso es lo que la Unidad 4 quiere decir cuando habla de que la preparación define el proyecto: no es la etapa más larga, es donde se toman las decisiones que después nadie revisa.

La advertencia que estuvimos cerca de cometer. Confundir una correlación fuerte con un hallazgo. Nuestra regla `Palitos Helados → Detergente` tiene lift 7,45, el cuarto más alto del dataset, y no hay ninguna explicación de por qué alguien compraría helado con detergente. Si ordenábamos por lift y presentábamos las primeras, entraba sin discusión. Lo evitamos aplicando el paso 4 —exigirle a cada regla un mecanismo de negocio— antes que el orden por lift, y después recalculando el lift por año: las reglas con explicación varían menos del 12 %, las implausibles nunca menos del 29 %. Peor todavía, hay pares que pasan de lift 0,08 a 4,52 entre 2024 y 2025; eso no es un cambio de hábito sino un cambio en cómo se generaron los datos, y las métricas lo respaldaban igual.

El rol de la IA. Confiar ciegamente hubiera sido riesgoso en la interpretación. Si le preguntábamos qué mecanismo explica una regla, habría encontrado una justificación convincente para cualquier par de productos, incluso para helado con detergente. Los modelos generativos son muy buenos produciendo explicaciones plausibles, que es lo contrario de lo que necesita un paso que existe justamente para filtrar lo que suena razonable y no lo es. Por eso el juicio sobre el mecanismo lo tomamos primero nosotros y recién después lo contrastamos contra la estabilidad entre años, que sale de la base y no de una opinión.
